

ĐẠI HỌC QUỐC GIA TP.HCM
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỒ ÁN

**ĐỀ TÀI: PHÂN LOẠI ẢNH Y KHOA DỰA TÊN MÔ HÌNH HỌC
GIÁM SÁT YẾU (WEAKY-SUPERVISED) WLS-DR (WEAKLY
SUPERVISED LESION – AWARE DR – FRAMEWORK)**

MÔN: ỨNG DỤNG XỬ LÝ ẢNH SỐ VÀ VIDEO SỐ

Giáo viên: PSG.TS. Lý Quốc Ngọc

Nhóm: Nhóm 2

Sinh viên thực hiện: 22120170 - Nguyễn Trung Kiên

22120437 - Lê Đình Hoàng Vũ

TP. Hồ Chí Minh – Năm 2025

Contents

Chương 1. Giới thiệu.....	4
1.1. Bệnh vông mạc tiểu đường.....	4
1.2. Học giám sát yếu và vai trò trong phân loại ảnh y khoa.....	5
1.3. Ý nghĩa về khoa học của chủ đề.....	5
1.4. Ý nghĩa về ứng dụng của chủ đề.	6
1.5. Phát biểu bài toán.....	6
1. Đầu vào	6
2. Framework (Khung làm việc được đề xuất – WSL-DR / PSLT dựa vào bài báo tham khảo).....	7
3. Đầu ra.....	9
1.6. Đóng góp.....	9
1. Mục đích.....	9
2. Cài đặt mô hình dựa trên phương pháp	9
3. Thử nghiệm và so sánh	9
Chương 2. Các công trình nghiên cứu liên quan.....	9
2.1. Efficient multi-kernel multi-instance learning using weakly supervised and imbalanced data for diabetic retinopathy diagnosis (2018).[2].....	10
1. Nguyên lý	10
2. Đầu vào	10
3. Phương pháp.....	11
4. Đầu ra.....	12
2.2. Collaborative learning of weakly-supervised domain adaptation for diabetic retinopathy grading on retinal images (2022). [3]	12
1. Nguyên lý	12
2. Đầu vào (Input):.....	13
3. Phương pháp (Methodology – Framework WAD-Net):	13
4. Đầu ra:.....	15
2.3. Weakly Supervised Lesion Detection Guides Diabetic Retinopathy Grading (2024) [4].....	15
2.4. Bảng so sánh các công trình.....	15

1. Tên công trình/ Framework và tác vụ chính	15
2. Nguyên lý	16
3. Đầu vào	16
4. Đầu ra.....	17
4. Phương pháp (Các công đoạn chính trong phát biểu bài toán)	17
5. Hiệu suất.....	19
6. Ưu điểm.....	21
7. Hạn chế / Hướng phát triển	22
Chương 3. Giải pháp.	23
3.1. Bước 1: Tiền huấn luyện Mạng CNN Chú ý (Attention Convolutional Neural Networks pre-training).....	24
1. Mục đích:.....	24
2. Hoạt động:	24
3. Kết quả của bước này:	25
3.2. Bước 2: Huấn luyện Framework PLST (Prompt-based Lesion-fuse Swin Transformer).....	25
1. Mô-đun Chú ý (Attention Module): Tạo “Lesion Prompt”	25
2. Bộ mã hóa Trường Tiếp nhận Kênh dựa trên Prompt (PRCF Encoder - Prompt-based Receptive Channel Field Encoder): Hợp nhất thông tin.....	27
3. Mô-đun Phân loại (Classification Module): Đưa ra quyết định cuối cùng	29
4. (Tùy chọn) Mô-đun Thay thế (Alternative Module):.....	30
Chương 4. Cài đặt và thử nghiệm mô hình.....	30
4.1. Tiền huấn luyện mô hình CNN EfficientNet để tạo heatmap.....	30
4.2. Huấn luyện mô hình hoàn chỉnh WLS-DR	33
Chương 5. Hạn chế và hướng phát triển	34
5.1 Hạn chế.....	34
5.2 Hướng phát triển.....	35
Chương 6. Tham khảo.....	35

Chương 1. Giới thiệu

1.1. Bệnh võng mạc tiểu đường

Bệnh võng mạc tiểu đường (DR) là bệnh tiến triển mãn tính của hệ thống vi mạch võng mạc, là nguyên nhân gây mù lòa phổ biến nhất trong 50 năm qua. Nó vẫn là một biến chứng lớn của bệnh tiểu đường và là nguyên nhân gây mù lòa ở người lớn trên toàn thế giới. Tỷ lệ mắc DR dự kiến sẽ tăng theo cấp số nhân và ảnh hưởng đến hơn 366 triệu người trên toàn thế giới vào năm 2030 [2]. Mặc dù yếu tố nguy cơ cao, 75% trường hợp mù lòa do bệnh tiểu đường được biết là có thể phòng ngừa được. Người ta đã xác định rằng phát hiện sớm và điều trị kịp thời có thể làm giảm phát triển mất thị lực nghiêm trọng ở 60% các trường hợp. Điều rất quan trọng là phải chuẩn đoán bệnh võng mạc tiểu đường và cung cấp các phương pháp điều trị thích hợp để giảm thiểu tình trạng suy giảm thêm càng sớm càng tốt. Việc sàng lọc DR tự động bằng máy tính là một lĩnh vực được nghiên cứu sâu rộng và một số phương pháp khác nhau đã được phát triển trong quá khứ để giảm bớt gánh nặng cho các chuyên gia.

Cây phân lớp về bệnh võng mạc tiểu đường[1]:

Bệnh võng mạc đái tháo đường (Diabetic Retinopathy)

— 1. Không có bệnh võng mạc (No DR)

— 2. Võng mạc không tăng sinh (NPDR - Non proliferative DR)

— 2.1. Mức độ nhẹ (Mild NPDR)

— Vi phình mạch (microaneurysms)

— 2.2. Mức độ vừa (Moderate NPDR)

— Xuất huyết, xuất tiết, nhiều vi phình mạch hơn

— 2.3. Mức độ nặng (Severe NPDR)

— Xuất huyết võng mạc diện rộng

— Tắc mao mạch nhiều vùng

— Dấu hiệu "4-2-1" (Hemorrhages, Venous beading, IRMA)

— 3. Võng mạc tăng sinh (PDR - Proliferative DR)

— Tân mạch (neovascularization)

— Xuất huyết dịch kính (vitreous hemorrhage)

— Bong võng mạc do co kéo (tractional retinal detachment)

— * Phù hoàng điểm đái tháo đường (Diabetic Macular Edema - DME)

- Có thể xảy ra ở bất kỳ giai đoạn nào
- Focal (khu trú) hoặc Diffuse (lan tỏa)
- Là nguyên nhân chính gây giảm thị lực

WLS-DR (Weakly Supervised Lesion-Aware DR-Framework) là một framework tiên tiến, kết hợp mạng nơ-ron tích chập (CNN) và Transformer để phân loại ảnh võng mạc tiểu đường một cách hiệu quả. Trong đề án này chúng em sẽ trình bày chi tiết về mô hình WLS-DR, cách hoạt động, kết quả thực nghiệm và tiềm năng ứng dụng của nó dựa trên bài báo khoa học tham khảo.

1.2. Học giám sát yếu và vai trò trong phân loại ảnh y khoa

- Học giám sát yếu là gì

Học giám sát yếu (Weakly-Supervised Learning) là một nhánh của học máy, trong đó mô hình được huấn luyện với dữ liệu có nhãn không đầy đủ hoặc chỉ ở mức độ cao (như nhãn cấp hình ảnh thay vì cấp pixel). Điều này đặc biệt hữu ích trong lĩnh vực y khoa, nơi việc tạo chú thích chi tiết thường rất khó khăn.

- Ứng dụng trong WLS-DR

Trong WLS-DR, học giám sát yếu được sử dụng để phân loại mức độ nghiêm trọng của DR (ví dụ: không bệnh, nhẹ, trung bình, nặng, rất nặng) chỉ dựa trên nhãn cấp hình ảnh. Mô hình không cần biết chính xác vị trí của các tổn thương (như vi phình mạch, xuất huyết, hoặc tiết dịch cứng) mà vẫn có thể suy ra thông tin quan trọng từ ảnh.

1.3. Ý nghĩa về khoa học của chủ đề

- Ứng dụng “Prompt Learning” vào thị giác máy tính y khoa

Việc áp dụng khái niệm “prompt” (gợi ý) từ Xử lý Ngôn ngữ Tự nhiên (NLP) sang lĩnh vực thị giác máy tính, đặc biệt là cho phân tích hình ảnh y tế như bệnh võng mạc tiểu đường, là một hướng đi mới mẻ. Nó giúp các mô hình học sâu tập trung vào các đặc điểm quan trọng mà không cần giám sát chi tiết.

- Phát triển kỹ thuật học giám sát yếu (Weakly Supervised Learning)

Trong y khoa nói chung và bệnh DR nói riêng, việc dữ liệu hạn chế gây là một vấn đề phổ biến và tốn kém. Nghiên cứu đóng góp vào việc phát triển các phương pháp học máy hiệu quả hơn với dữ liệu hạn chế.

- Hướng tới mô hình Học Máy/Học Sâu có thể diễn giải

Bằng cách tập trung vào việc phát hiện và sử dụng thông tin tổn thương, các mô hình học máy/ học sâu có thể cung cấp sự diễn giải tốt hơn về quyết định của mô hình, giúp bác sĩ hiểu tại sao mô hình đưa ra một chuẩn đoán cụ thể. Điều này rất quan trọng để xây dựng lòng tin và chấp nhận các công cụ AI trong thực hành lâm sàng.

1.4. Ý nghĩa về ứng dụng của chủ đề.

- **Cải thiện chuẩn đoán sớm và chính xác bệnh võng mạc tiểu đường**

Mục tiêu cuối cùng là phát triển một công cụ và hỗ trợ chuẩn đoán DR chính xác hơn và sớm hơn. Phát hiện sớm và phân loại đúng mức độ bệnh giúp can thiệp kịp thời, ngăn ngừa mất thị lực cho bệnh nhân tiểu đường.

- **Giảm gánh nặng cho các chuyên gia y tế**

Các hệ thống AI tự động có thể giúp sàng lọc một lượng lớn hình ảnh đáy mắt, giảm tải công việc cho bác sĩ nhãn khoa, đặc biệt ở những nơi thiếu chuyên gia hoặc trong các chương trình sàng lọc quy mô lớn.

- **Khả năng tiếp cận dịch vụ y tế**

Một hệ thống AI hiệu quả, đặc biệt là một hệ thống được xây dựng dựa trên dữ liệu có thể tiếp cận và không cần quá nhiều chi phí cho dữ liệu, có thể triển khai ở các đất nước đang phát triển, nơi việc tiếp cận các chuyên gia nhãn khoa còn hạn chế.

- **Công cụ hỗ trợ quyết định lâm sàng tiềm năng**

Nếu hệ thống đủ tin cậy và có khả năng diễn giải tốt, nó có thể trở thành một công cụ hỗ trợ đắc lực cho bác sĩ trong việc đưa ra quyết định điều trị, đặc biệt trong các trường hợp phức tạp hoặc khi cần một “ý kiến thứ hai”.

1.5. Phát biểu bài toán

Xây dựng một mô hình học sâu có khả năng tự động phân loại chính xác mức độ nghiêm trọng của bệnh võng mạc tiểu đường từ ảnh đáy mắt (fundus images) mà **chỉ sử dụng nhãn ở cấp độ hình ảnh (image-level labels)** cho việc huấn luyện. Mô hình cần có khả năng nhận diện ngầm các vùng tổn thương (lesion-aware) để cải thiện hiệu suất phân loại, ngay cả khi không được cung cấp thông tin chú thích chi tiết về vị trí tổn thương ở cấp độ pixel.

1. Đầu vào

- Ảnh đáy mắt (Fundus Images): Một tập hợp các ảnh màu chụp đáy mắt của bệnh nhân.
- Nhãn cấp độ hình ảnh (Image-level Labels) cho việc huấn luyện. Đối với mỗi ảnh đáy mắt trong tập huấn luyện có một nhãn duy nhất chỉ ra mức độ nghiêm trọng tổng thể của bệnh võng mạc tiểu đường.
 - o Ví dụ (Theo tập EyePACS dataset):
 - 0: No DR (Không có DR)

- 1: Mild DR (DR nhẹ)
- 2: Moderate DR (DR trung bình)
- 3: Severe DR (DR nặng)
- 4: Proliferative DR (DR tăng sinh)
- Quan trọng là **không có thông tin về vị trí tổn hay loại tổn thương cụ thể** (như vị phình mạch, xuất huyết) được cung cấp dưới dạng chú thích pixel hoặc bounding box.

2. Framework (Khung làm việc được đề xuất – WSL-DR / PSLT dựa vào bài báo tham khảo)

Framework WLS-DR (cụ thể là PLST – Prompt-based Lesion-fuse Swin Transformer) là một kiến trúc lai CNN – Transformer hoạt động theo hai giai đoạn chính trong quá trình huấn luyện và một giai đoạn kiểm thử/ suy luận:




Figure 1: Cấu trúc tổng thể của khung Swin Transformer Lesion-fuse dựa trên Lời Nhắc(PLST)

Giai đoạn 1: Tiền huấn luyện Mạng CNN Chú ý (Attention Convolutional Neural Networks pre-training):

- **Mục đích:** Huấn luyện một mạng CNN (EfficientNet) để nắm bắt các vùng tổn thương đáng ngờ chỉ dựa trên cấp độ hình ảnh
- **Hoạt động:** EfficientNet được huấn luyện để phân loại mức độ DR. Sau đó, Grad-CAM được sử dụng để tạo ra “bản đồ chú ý” (heatmap) làm nổi bật các vùng mà mạng tập trung vào để đưa ra quyết định phân loại. Bản đồ này được coi là một dạng biểu diễn yếu của các vùng tổn thương
- Hàm mất mát được sử dụng là **Mean Squared Error (MSE)**

Giai đoạn 2: Huấn luyện Framework PLST (Prompt-based Lesion-fuse Swin Transformer):

- **Mục đích:** Tích hợp thông tin tổn thương (dưới dạng “prompt”) với thông tin toàn cục của ảnh để phân loại DR cuối cùng.

- **Các thành phần chính của PLST:**

○ **Mô-đun Chú ý (Attention Module):**

- Sử dụng EfficientNet đã tiền huấn luyện và Grad-CAM để tạo ra “heatmap” Y_G từ ảnh đầu vào.
- Chuẩn hóa heatmap Y_G để có được “bản đồ trọng số” V .
- Thực hiện phép nhân Hadamard giữa bản đồ trọng số V và ảnh gốc P để tạo ra “Lesion Prompt” G ($g_i = P_i \otimes v_i$). Đây là một phiên bản của ảnh chỉ giữ lại các vùng tổn thương đáng ngờ, loại bỏ nhiều nền.

○ **Bộ mã hóa Trường Tiếp nhận Kênh dựa trên Prompt (PRCF**

Encoder - Prompt-based Receptive Channel Field encoder):

- **Nối (Concatenate)** “Lesion Prompt” G với ảnh gốc P để tạo ra đặc trưng kết hợp F ($F = \text{concat}[P, G]$).
- **Mô-đun Hợp nhất Kênh (Channel Fusion Module):**
 - Áp dụng Global Average Pooling lên F để có được thống kê trên kênh z_c
 - Sử dụng hai lớp Fully-Connected (FC) với hàm kích hoạt ReLU và Sigmoid (tương tự SENet) để tạo ra trọng số kênh s . ($s = \sigma(W_2 \delta W_1 z)$)
 - Nhân trọng số kênh s với đặc trưng F để có được đặc trưng mới $\tilde{f}_c = \mathbf{F}_{rescale}(f_c, s_c) = s_c f_c$
 -
- **Mô-đun Tiếp nhận (Receptive Module):**
 - Đưa đặc trưng $\tilde{F}_c$ (từ Channel Fusion Module) qua các hạt nhân tích chập đa tỷ lệ (multi-convolution kernels with different scales).
 - Cộng (add) đặc trưng đã hợp nhất này với thông tin ảnh toàn cục gốc P (dưới dạng kết nối dư - residual connection) để tăng tính ổn định và khả năng phân biệt.
- **Mô-đun Phân loại (Classification Module):**
 - Đặc trưng đầu ra từ PRCF Encoder được đưa vào một mạng Swin Transformer. Swin Transformer xử lý các đặc trưng này (chia thành patch, linear embedding, các khối Swin Transformer Block, patch merging) để đưa ra kết quả phân loại DR cuối cùng.
 - Hàm mất mát sử dụng là Cls Loss (thường là Cross-Entropy cho bài toán phân loại đa lớp).
- **(Tùy chọn) Mô-đun Thay thế (Alternative Module):** Đối với các bộ dữ liệu cung cấp ảnh của cả hai mắt (ví dụ: EyePACS),

mô-đun này kết hợp đặc trưng từ cả hai mắt (đã qua Classification Module) bằng một mạng nhỏ gồm ba lớp FC để cải thiện hiệu suất.

3. Đầu ra

- **Mức độ nghiêm trọng dự đoán của Bệnh Vỡ mạc Tiểu đường (Predicted DR Severity Level):** Đối với mỗi ảnh đáy mắt đầu vào (trong tập kiểm thử hoặc ứng dụng thực tế), mô hình sẽ đưa ra một nhãn dự đoán về mức độ nghiêm trọng của DR.
- **(Phụ) Bản đồ chú ý về vị trí tổn thương (Suspicious Lesion Position Attention Map):** Các bản đồ trực quan hóa từ CNN Attention hoặc đầu ra của PRCF cho thấy các vùng mà mô hình cho là quan trọng, giúp tăng tính diễn giải.

1.6. Đóng góp

1. Mục đích

Chúng em giới thiệu sự đóng góp của mình thông qua việc xây dựng và cài đặt mô hình dựa trên nghiên cứu mới nhất. Điều này không chỉ giúp chúng em hiểu rõ hơn về ứng dụng thực tế và nhu cầu ứng dụng Thị giác máy tính trong lĩnh vực Y Khoa.

2. Cài đặt mô hình dựa trên phương pháp

Chúng em cài đặt lại mô hình dựa trên các phương pháp được trình bày trong bài báo. Tuy hiệu suất không được tốt như trong bài báo, nhưng mô hình được xây dựng sát với lý thuyết. Quá trình này đòi hỏi nhiều kỹ năng và thời gian để triển khai và thực hành mô hình.

3. Thử nghiệm và so sánh

Chúng em đã tiến hành cài đặt và thử nghiệm. Hiệu suất không được tốt lắm do hạn chế về thiết bị và thời gian, tuy nhiên điều đó cũng chứng tỏ mô hình có thể đạt được hiệu suất tốt hơn và có khả năng mở rộng của mô hình trong quá trình xây dựng.

Chương 2. Các công trình nghiên cứu liên quan

2.1. Efficient multi-kernel multi-instance learning using weakly supervised and imbalanced data for diabetic retinopathy diagnosis (2018).[2]

1. Nguyên lý

- **Học đa ví dụ (Multi-Instance Learning - MIL):** Giải quyết bài toán chẩn đoán DR khi chỉ có nhãn ở cấp độ toàn bộ ảnh (bag - túi) mà không có nhãn chi tiết cho từng vùng tổn thương ứng viên (instance - thực thể). Mỗi ảnh đáy mắt (fundus image) được xem là một "túi", và các vùng nghi ngờ có tổn thương xuất huyết/vi phình mạch (HMA - Hemorrhagic and Microaneurysm) được phát hiện tự động được xem là các "thực thể" bên trong túi đó.
- **Giám sát yếu (Weakly Supervised):** Chỉ sử dụng nhãn toàn cục của ảnh (ví dụ: có DR hoặc không có DR, hoặc các cấp độ DR) để huấn luyện mô hình, thay vì yêu cầu chú thích vị trí chính xác của từng tổn thương.
- **Học đa nhân (Multi-Kernel Learning - MKL):** Sử dụng nhiều hàm kernel khác nhau để ánh xạ dữ liệu sang các không gian đặc trưng khác nhau và sau đó kết hợp chúng một cách tối ưu. Điều này giúp nắm bắt các mối quan hệ phi tuyến phức tạp trong dữ liệu và cải thiện khả năng tổng quát hóa. Các kernel được xây dựng dựa trên cấu trúc đồ thị của các thực thể trong mỗi túi.
- **Xử lý dữ liệu mất cân bằng (Imbalanced Data):** Đề xuất các kỹ thuật lấy mẫu lại (re-sampling) ở hai cấp độ:
 - **Cấp độ thực thể (Instance-level under-sampling - BUS - Bag Under-Sampling):** Lọc bỏ các thực thể (vùng tổn thương ứng viên) không liên quan hoặc gây nhiễu bên trong mỗi túi, đặc biệt là các dương tính giả (false positives) từ bước phát hiện HMA ban đầu. Kỹ thuật này dựa trên việc sử dụng một bộ phân loại được huấn luyện trên một tập dữ liệu nguồn (e-ophtha) để gán trọng số hoặc lọc các thực thể trong tập dữ liệu đích (Messidor).
 - **Cấp độ túi (Bag-level over-sampling - BOS - Bag Over-Sampling):** Mở rộng kỹ thuật SMOTE (Synthetic Minority Over-sampling Technique) cho bài toán MIL để tạo ra các túi tổng hợp cho lớp thiểu số (ví dụ: các túi ảnh có DR), nhằm cân bằng số lượng mẫu giữa các lớp.

2. Đầu vào

1. **Ảnh đáy mắt (Fundus Images):** Ví dụ, từ bộ dữ liệu Messidor.
2. **Các vùng tổn thương ứng viên (HMA Candidates - Instances):** Được phát hiện tự động từ ảnh đáy mắt bằng một thuật toán phát hiện HMA (như đã mô tả trong công trình trước đó của nhóm tác giả trong bài báo MKMIL). Mỗi HMA candidate là một thực thể.

3. **Nhãn cấp độ ảnh (Image-level Labels - Bag Labels):** Cho mỗi ảnh, có một nhãn chỉ ra tình trạng DR (ví dụ: khỏe mạnh/không DR, hoặc các cấp độ DR L0, L1, L2, L3).
4. **(Tùy chọn cho BUS) Dữ liệu nguồn có nhãn thực thể:** Một tập dữ liệu phụ (ví dụ: e-ophta) nơi có thông tin ground truth về các tổn thương thật sự, dùng để huấn luyện bộ phân loại cho việc lọc thực thể ở tập đích.

3. Phương pháp

1. Tạo thực thể (Instance Generation):

- Sử dụng thuật toán phát hiện HMA (ví dụ: phát hiện và loại bỏ mạch máu, trích xuất mầm HMA, phát triển vùng ràng buộc) để xác định các vùng tổn thương ứng viên từ mỗi ảnh đáy mắt.
- Trích xuất 37 đặc trưng hình ảnh (màu sắc, hình dạng, kết cấu, gradient) cho mỗi HMA ứng viên.

2. Lấy mẫu lại dưới cấp độ túi (Bag Under-Sampling - BUS):

- Mục tiêu: Giảm số lượng dương tính giả (FP) trong các thực thể của mỗi túi.
- Sử dụng một bộ phân loại (ví dụ: ELM) được huấn luyện trên một tập dữ liệu nguồn (e-ophta, nơi có ground truth của tổn thương) để dự đoán xác suất một HMA ứng viên ở tập đích (Messidor) là tổn thương thật.
- Ước tính trọng số lấy mẫu (sampling weights γ) để giảm thiểu sự khác biệt phân phối giữa tập nguồn và tập đích.
- Lọc bỏ các thực thể có điểm xác suất thấp hơn một ngưỡng (S).

3. Xây dựng đồ thị và Kernel đồ thị (Graph Construction and Graph Kernel Computation):

- Với mỗi túi (ảnh), xây dựng một đồ thị vô hướng trong đó mỗi nút là một thực thể (HMA ứng viên đã qua lọc) và các cạnh biểu thị mối quan hệ/sự tương đồng giữa các thực thể.
- Sử dụng nhiều hàm kernel khác nhau (ví dụ: RBF với các băng thông khác nhau, polynomial, linear) để tính toán sự tương đồng giữa các cặp thực thể, từ đó xây dựng các ma trận kề cho đồ thị.
- Tính toán kernel đồ thị (graph kernel) giữa các cặp túi, dựa trên sự tương đồng cấu trúc của các đồ thị tương ứng. Điều này tạo ra nhiều biểu diễn kernel khác nhau cho mỗi cặp túi.

4. Lấy mẫu lại trên cấp độ túi (Bag Over-Sampling - BOS):

- Mục tiêu: Cân bằng số lượng túi giữa các lớp DR (đặc biệt là lớp thiểu số).

- Mở rộng thuật toán SMOTE cho không gian túi.
- Chọn các túi thuộc lớp thiểu số, tìm các láng giềng gần nhất (dựa trên Gram matrix từ các kernel đồ thị).
- Tạo ra các túi tổng hợp mới nằm trên đường nối giữa một túi thiểu số và một láng giềng của nó. Các thực thể trong túi tổng hợp được tạo ra bằng cách chọn các thực thể từ túi gốc dựa trên trọng số (để ưu tiên các thực thể có khả năng là tổn thương thật).

5. Học đa nhân đa ví dụ (Multi-Kernel Multi-Instance Learning - MKMIL):

- Kết hợp các kernel đồ thị đã tính toán ở bước 3 (và có thể đã được tăng cường bởi BOS ở bước 4) bằng cách học một tổ hợp tuyến tính tối ưu của chúng.
- Sử dụng một bộ phân loại dựa trên MKL (ví dụ: SVM-MKL) để huấn luyện mô hình trên các túi (ảnh) đã được biểu diễn bằng tổ hợp kernel tối ưu.
- Tối ưu hóa đồng thời trọng số của các kernel và tham số của bộ phân loại.

4. Đầu ra

1. **Dự đoán nhãn DR cho ảnh đầu vào:** Ví dụ, phân loại ảnh là "Không DR" hoặc "Có DR", hoặc phân loại thành các cấp độ cụ thể (L0, L1, L2, L3).
2. **(Ngầm định) Trọng số của các kernel:** Cho biết mức độ đóng góp của từng loại đặc trưng/kernel vào việc phân loại.
3. **(Ngầm định) Xác suất các thực thể là tổn thương:** Thông qua bước BUS, có thể có thông tin về mức độ "ngghi ngờ" của từng HMA ứng viên.

2.2. Collaborative learning of weakly-supervised domain adaptation for diabetic retinopathy grading on retinal images (2022). [3]

1. Nguyên lý

- **Thích ứng tên miền giám sát yếu (Weakly-Supervised Domain Adaptation - WDA):** Giải quyết vấn đề phân loại DR khi có sự khác biệt (domain shift) giữa miền nguồn (source domain - ví dụ: IDRID, nơi có thể có chú thích chi tiết hơn ở cấp độ tổn thương hoặc patch) và miền đích (target domain - ví dụ: Messidor, EyePACS, nơi chủ yếu chỉ có nhãn cấp độ ảnh). Mục tiêu là chuyển giao kiến thức từ miền nguồn sang miền đích một cách hiệu quả dù chỉ có giám sát yếu ở miền đích.

- **Học đa ví dụ (Multi-Instance Learning - MIL):** Tương tự như công trình trước, ảnh đáy mắt ở miền đích được xem là "túi" (bag), và các patch (mảnh) của ảnh được xem là "thực thể" (instances).
- **Học phối hợp (Collaborative Learning):** Ba thành phần chính của framework được thiết kế để học hỏi và hỗ trợ lẫn nhau trong một quy trình huấn luyện end-to-end:
 - **Thích ứng tên miền (Domain Adaptation):** Sử dụng CycleGAN để dịch ảnh giữa hai miền, nhằm giảm sự khác biệt về mặt hình ảnh.
 - **Bộ phân biệt thực thể tiến bộ (Instance Progressive Discriminator):** Một bộ phân loại ở cấp độ thực thể (patch) được huấn luyện để phát hiện các tổn thương. Nó được tiền huấn luyện trên miền nguồn và sau đó được tinh chỉnh (fine-tuned) trên các patch được tạo ra/dịch sang miền đích.
 - **Học đa ví dụ với cơ chế chú ý (Multi-Instance Learning with Attention):** Một mô hình MIL sử dụng cơ chế chú ý để tổng hợp thông tin từ các patch (thực thể) và đưa ra dự đoán cấp độ ảnh (túi), đồng thời làm nổi bật các vùng tổn thương quan trọng.
- **Khả năng diễn giải (Interpretability):** Cơ chế chú ý trong mô hình MIL giúp xác định các vùng tổn thương đáng ngờ, cung cấp sự diễn giải cho quyết định của mô hình.

2. Đầu vào (Input):

1. Dữ liệu miền nguồn (Source Domain Data - D_s):

- Ảnh đáy mắt từ miền nguồn (ví dụ: IDRID).
- Chú thích ở cấp độ thực thể (instance-level/lesion-wise labels) cho các tổn thương trong ảnh miền nguồn. Đây là các patch chứa tổn thương hoặc không chứa tổn thương.

2. Dữ liệu miền đích (Target Domain Data - D_t):

- Ảnh đáy mắt từ miền đích (ví dụ: Messidor, EyePACS).
- Chỉ có nhãn cấp độ ảnh (image-level labels) cho biết mức độ DR tổng thể của ảnh.

Lưu ý: Tồn tại sự khác biệt về phân phối dữ liệu (domain gap) giữa D_s và D_t .

3. Phương pháp (Methodology – Framework WAD-Net):

Framework WAD-Net (Weakly supervised learning network with Attention mechanism and Domain adaptation) bao gồm các bước chính sau:

1. **Tiền huấn luyện Bộ phân biệt thực thể (Instance Discriminator Pre-training - trên miền nguồn):**

- Huấn luyện một bộ phân biệt $C_{DI}(\cdot)$ (ví dụ: một CNN) trên các patch từ miền nguồn D_s với các nhãn tổn thương chi tiết. Mục tiêu là để C_{DI} có khả năng phân biệt patch chứa tổn thương và các patch không chứa tổn thương.
- 2. Thích ứng tên miền bằng CycleGAN (Domain Adaptation with CycleGAN - giữa hai miền):**
- Huấn luyện một mô hình CycleGAN ($G_{S \rightarrow T}$ và $G_{T \rightarrow S}$) để học ánh xạ chuyển đổi hình ảnh giữa miền nguồn và miền đích mà không cần các cặp ảnh tương ứng (unpaired image-to-image translation). Điều này giúp tạo ra các phiên bản “giống miền đích” của ảnh nguồn và ngược lại, nhằm giảm domain gap.
 - Sử dụng các hàm mất mát adversarial (L_{adv}) và mất mát chu trình (cycle consistency loss – L_{cyc}) để huấn luyện CycleGAN.
- 3. Tinh chỉnh Bộ phân biệt thực thể (Fine-tuning Instance Discriminator - trên các thực thể được tạo ra):**
- Sử dụng CycleGAN ($G_{S \rightarrow T}$) để dịch các patch từ miền nguồn sang phong cách của miền đích.
 - Tiếp tục huấn luyện (fine-tune) bộ phân biệt $C_{DI}(\cdot)$ trên các patch đã được dịch này, sử dụng nhãn tổn thương gốc từ miền nguồn. Điều này giúp C_{DI} thích ứng tốt hơn với đặc điểm hình ảnh của miền đích.
- 4. Học đa ví dụ với Cơ chế Chú ý (MIL with Attention Mechanism - trên miền đích):**
- Ảnh từ miền đích D_t được chia thành các patch.
 - Các patch này được đưa qua bộ phân biệt thực thể $C_{DI}(\cdot)$ (đã được tinh chỉnh) để thu được bản đồ điểm số tổn thương đáng ngờ (suspected lesion patches score map S_n). Điểm số này cho biết khả năng mỗi patch chứa tổn thương.
 - Các đặc trưng patch được học (Patch Feature Learning)
 - Một mô hình MIL dựa trên cơ chế chú ý ($C_{DM}(\cdot)$) được sử dụng. Cơ chế chú ý tính toán trọng số α_k^{ij} cho mỗi patch j của ảnh i đối với lớp bệnh k . Trọng số này phản ánh mức độ quan trọng của patch đó.
 - Các embedding của patch được nhân với trọng số chú ý tương ứng. Các trọng số này được tổng hợp để tạo ra biểu diễn cho toàn bộ ảnh (túi).
 - Biểu diễn túi này sau đó được đưa qua các lớp fully-connected để dự đoán nhãn cấp độ ảnh (mức độ DR).
 - Hàm mất mát cho MIL là multi-class-cross-entropy loss (L_{CM}).
- 5. Huấn luyện phối hợp End-to-End:**
- Toàn bộ các thành phần (CycleGAN, Instance Discriminator MIL with Attention) được tối ưu hóa đồng thời trong một hàm mục tiêu tổng thể, bao

gồm các thành phần mất mát từ domain adaption (L_{adv} , L_{eye}), instance discriminator (L_{CI}), và MIL (L_{CM}).

- Việc học phối hợp này cho phép các thành phần tương tác và cải thiện lẫn nhau::
 - CycleGAN cung cấp các patch chất lượng hơn cho bộ phân biệt.
 - Bộ phân biệt cung cấp điểm số tổn thương chính xác hơn cho mô hình MIL.
 - Mô hình MIL cung cấp tín hiệu giám sát ngược lại cho CycleGAN và bộ phân biệt.

4. Đầu ra:

1. Dự đoán mức độ nghiêm trọng DR cho ảnh ở miền đích.
2. Bản đồ chú ý (Attention Map): Trực quan hóa các vùng (patch) trong ảnh miền đích mà mô hình MIL tập trung vào, giúp xác định các vùng tổn thương đáng ngờ và khả năng diễn giải.

2.3. Weakly Supervised Lesion Detection Guides Diabetic Retinopathy Grading (2024) [4].

Bài báo cáo này chính là bài khảo sát của bài báo này, từ nguyên lý đến phương pháp.

Vì thế nên trong phần này tui em sẽ không trình bày phương pháp và nguyên lý vì những phần đó đã được trình bày từ đầu trong báo cáo. Nhưng tui em vẫn sẽ đề cập các thông tin của bài báo này trong bảng so sánh các công trình (các thông tin bao gồm: Các tác vụ chính, hiệu suất, ưu điểm và nhược điểm). Các tiêu chí khác đã được nêu trong phần phát biểu bài toán, tui em sẽ không đề cập lại để tránh trùng lặp nội dung.

2.4. Bảng so sánh các công trình

1. Tên công trình/ Framework và tác vụ chính

Tên công trình/ Framework	Năm công bố	Tác vụ chính
MKMIL (Multi-Kernel Multi-Instance Learning)	2018	Chẩn đoán/Phân loại Bệnh Vồng mạc Tiểu đường (DR), thường là nhị phân (DR vs No DR, L0 vs L1) hoặc đa lớp ở mức độ túi (ảnh).
WAD-Net (Weakly supervised learning)	2022	Phân loại mức độ nghiêm trọng của DR (đa lớp) với việc giải quyết vấn đề thích ứng tên

network with Attention mechanism and Domain adaptation)		miền (domain adaptation) giữa các tập dữ liệu khác nhau.
WSL-DR (Weakly Supervised Lesion Detection Guides Diabetic Retinopathy Grading)	2024	Phân loại mức độ nghiêm trọng của DR chỉ dựa vào dữ liệu có nhãn ở cấp độ ảnh

2. Nguyên lý

Tên công trình/ FrameWork	Nguyên lý
MKMIL (Multi-Kernel Multi-Instance Learning) (2018)	- Học Đa Ví dụ (MIL): Ảnh là "túi", vùng tổn thương ứng viên (HMA candidate) là "thực thể". Nhãn chỉ có ở cấp độ túi. - Giám Sát Yếu: Chỉ sử dụng nhãn cấp độ ảnh. - Học Đa Nhân (MKL): Kết hợp nhiều kernel đồ thị để nắm bắt mối quan hệ phi tuyến và chọn lựa tổ hợp kernel tối ưu. - Xử lý Dữ liệu Mất Cân Bằng: Sử dụng Bag Under-Sampling (BUS) cho thực thể và Bag Over-Sampling (BOS) cho túi.
WAD-Net (Weakly supervised learning network with Attention mechanism and Domain adaptation (2018)	- Thích ứng Tên Miền Giám Sát Yếu (WDA): Chuyển giao kiến thức từ miền nguồn (có chú thích tốt hơn) sang miền đích (chỉ nhãn ảnh) bằng CycleGAN và bộ phân biệt thực thể. - Học Đa Ví dụ (MIL) với Cơ chế Chú ý: Patch ảnh là thực thể, sử dụng chú ý để tổng hợp thông tin từ patch và làm nổi bật vùng tổn thương. - Học Phối Hợp (Collaborative Learning): Ba thành phần (Domain Adaptation, Instance Discriminator, MIL-Attention) được huấn luyện end-to-end, hỗ trợ lẫn nhau. - Khả năng Diễn giải: Cơ chế chú ý cung cấp bản đồ trực quan hóa vùng tổn thương.

3. Đầu vào

Công trình/ Framework	Đầu vào chính	Loại Chú thích/ Nhãn
Efficient multi-kernel multi-instance learning using weakly supervised and imbalanced data for	- Ảnh đáy mắt (Fundus Images), ví dụ: từ tập Messidor. - Các vùng tổn thương ứng viên (HMA Candidates -	- Nhãn cấp độ ảnh (Bag Labels): Cho mỗi ảnh, chỉ ra tình trạng DR (ví dụ: khỏe mạnh/không DR, hoặc các cấp độ DR L0, L1, L2, L3).

diabetic retinopathy diagnosis (2018)	Instances) được phát hiện tự động từ ảnh đáy mắt.	- Không có nhãn chi tiết cho từng HMA candidate ở tập dữ liệu đích.
Collaborative learning of weakly-supervised domain adaptation for diabetic retinopathy grading on retinal images (2022)	- Dữ liệu miền nguồn (D_s): - Ảnh đáy mắt (ví dụ: IDRID) và các patch (thực thể) từ ảnh đó. - Dữ liệu miền đích (D_t): Ảnh đáy mắt (ví dụ: Messidor, EyePACS) và các patch (thực thể) từ ảnh đó.	- Miền nguồn: Chú thích ở cấp độ thực thể (patch-level/lesion-wise labels) cho biết patch có chứa tổn thương hay không. - Miền đích: Chỉ có nhãn cấp độ ảnh (image-level labels) cho biết mức độ DR tổng thể.

4. Đầu ra

Công trình/ Framework	Đầu ra chính	Đầu ra phụ/ Trung gian (Có ý nghĩa diễn giải)
Efficient multi-kernel multi-instance learning using weakly supervised and imbalanced data for diabetic retinopathy diagnosis (2018)	- Dự đoán nhãn DR cho ảnh đầu vào (L0-L3).	- Trọng số của các kernel (từ MKL, cho biết mức độ đóng góp của từng loại đặc trưng/kernel). - (Ngầm định) Xác suất các HMA candidate là tổn thương thật (từ bước BUS). - Các túi tổng hợp (từ bước BOS).
Collaborative learning of weakly-supervised domain adaptation for diabetic retinopathy grading on retinal images (2022)	- Dự đoán mức độ nghiêm trọng DR cho ảnh ở miền đích.	- Bản đồ chú ý (Attention Map) làm nổi bật các vùng (patch) quan trọng trong ảnh miền đích. - Ảnh đã được dịch giữa các miền (từ CycleGAN). - Điểm số tổn thương cho từng patch (từ Instance Discriminator).

4. Phương pháp (Các công đoạn chính trong phát biểu bài toán)

Công trình/ Framework	Các công đoạn chính của phương pháp
Efficient multi-kernel multi-instance learning using weakly supervised and imbalanced data	1. Tạo thực thể (Instance Generation): - Phát hiện HMA (Hemorrhagic and Microaneurysm) candidates từ ảnh đáy mắt bằng

for diabetic retinopathy diagnosis (2018)

thuật toán gồm: phát hiện và loại bỏ mạch máu, trích xuất mầm HMA, phát triển vùng ràng buộc.
- Trích xuất 37 đặc trưng hình ảnh (màu sắc, hình dạng, kết cấu, gradient) cho mỗi HMA candidate.

2. Lấy mẫu lại dưới cấp độ thực thể (Bag Under-Sampling - BUS):

- **Mục tiêu:** Giảm số lượng dương tính giả (FP) trong các thực thể của mỗi túi (ảnh).
- **Phương pháp:** Sử dụng một bộ phân loại (ví dụ: ELM) được huấn luyện trên một tập dữ liệu nguồn (e-optha, nơi có ground truth của tổn thương) để dự đoán xác suất một HMA candidate ở tập đích (Messidor) là tổn thương thật.
- Ước tính trọng số lấy mẫu (γ) để giảm thiểu sự khác biệt phân phối giữa tập nguồn và tập đích, sau đó lọc bỏ các thực thể có điểm xác suất thấp hơn một ngưỡng (S).

3. Xây dựng Kernel đồ thị (Graph Kernel Construction):

- Với mỗi túi (ảnh), xây dựng một đồ thị vô hướng trong đó mỗi nút là một thực thể (HMA candidate đã qua lọc).
- Sử dụng nhiều hàm kernel (RBF với các băng thông khác nhau, polynomial, linear) để tính toán ma trận tương đồng giữa các thực thể, từ đó xây dựng các kernel đồ thị giữa các cặp túi.

4. Lấy mẫu lại trên cấp độ túi (Bag Over-Sampling - BOS):

- **Mục tiêu:** Cân bằng số lượng túi giữa các lớp DR, đặc biệt là lớp thiểu số.
- **Phương pháp:** Mở rộng thuật toán SMOTE cho không gian túi. Tạo túi tổng hợp mới bằng cách tìm các túi láng giềng gần nhất của túi thiểu số và tạo ra các thực thể mới cho túi tổng hợp dựa trên trọng số của thực thể gốc.

5. Học đa nhân đa ví dụ (Multi-Kernel Multi-Instance Learning - MKMIL):

	- Kết hợp các kernel đồ thị đã tính toán (và có thể đã được tăng cường bởi BOS) bằng cách học một tổ hợp tuyến tính tối ưu của chúng. - Huấn luyện một bộ phân loại dựa trên MKL (ví dụ: SVM-MKL) trên các túi (ảnh) đã được biểu diễn bằng tổ hợp kernel tối ưu.
Collaborative learning of weakly-supervised domain adaptation for diabetic retinopathy grading on retinal images (2022)	1. Tiềm huấn luyện Bộ phân biệt thực thể (C_{DI}): - Huấn luyện một bộ phân biệt $C_{DI}(\cdot)$ (ví dụ: một CNN) trên các patch từ miền nguồn D_s với các nhãn tổn thương chi tiết. - Mục tiêu là để C_{DI} có khả năng phân biệt patch chứa tổn thương và các patch không chứa tổn thương. 2. Thích ứng tên miền (CycleGAN): - Huấn luyện một mô hình CycleGAN ($G_{S \rightarrow T}$ và $G_{T \rightarrow S}$) để học ánh xạ chuyển đổi hình ảnh giữa miền nguồn và miền đích mà không cần các cặp ảnh tương ứng, sử dụng (L_{adv} và L_{eye}) 3. Tinh chỉnh Bộ phân biệt thực thể (C_{DI}): - Sử dụng CycleGAN ($G_{S \rightarrow T}$) để dịch các patch từ miền nguồn sang phong cách của miền đích. - Tinh chỉnh C_{DI} trên các patch đã dịch này, sử dụng nhãn tổn thương gốc từ miền nguồn 4. Học đa ví dụ với Cơ chế Chú ý (MIL with Attention - C_{DM}): - Ảnh miền đích D_t được chia thành các patch. - Các patch qua C_{DI} (đã tinh chỉnh) để lấy “bản đồ điểm số tổn thương”. - Cơ chế chú ý tính toán trọng số α cho mỗi patch. - Embedding của patch được nhân với trọng số chú ý, sau đó tổng hợp để tạo biểu diễn túi. - Biểu diễn túi qua các lớp FC để dự đoán nhãn cấp độ ảnh (mức độ DR) với L_{CM}. 5. Huấn luyện Phối hợp End-to-End: - Tối ưu hóa đồng thời CycleGAN, C_{DI} và C_{DM} với hàm mục tiêu tổng thể.

5. Hiệu suất

Công trình/ Framework	Tập dữ liệu chính được đánh giá	Độ đo chính	Kết quả tổng quan nổi bật
Efficient multi-kernel multi-instance learning using weakly supervised and imbalanced data for diabetic retinopathy diagnosis (2018)	Messidor	Accuracy, AUC, Sensitivity, Specificity, G-mean	- Đạt Accuracy cao (ví dụ: 0.932 cho mkmi-Graph-BUS trong DR vs. No DR, 0.916 cho mkmi-Graph-BOUS trong L0 vs. L1). - AUC cao (ví dụ: 0.945, 0.957 tương ứng). - Vượt trội hơn các phương pháp MIL baseline và supervised learning trên e-optha.
Collaborative learning of weakly-supervised domain adaptation for diabetic retinopathy grading on retinal images (2022)	Messidor, EyePACS	Accuracy, Quadratic Weighted Kappa (QWK), AUC, Precision, Recall, F1-score.	- Trên Messidor (đa lớp): WAD-Net đạt Accuracy 0.712, AUC 0.808. - Trên EyePACS (đa lớp): WAD-Net đạt QWK 0.860. - Vượt trội hơn các phương pháp không có thích ứng tên miền hoặc các thành phần học phối hợp. - Khả năng diễn giải tốt qua bản đồ chú ý.
Weakly Supervised Lesion Detection Guides Diabetic Retinopathy Grading (2024)	EyePACS, Messidor	Quadratic Weighted Kappa (QWK), Accuracy, Precision, Recall, F1-score, AUC.	- Trên EyePACS: WSL-DR đạt QWK 0.856. - Trên Messidor: WSL-DR đạt Accuracy 0.784, AUC 0.895. - Vượt trội hơn nhiều phương pháp state-of-the-art chỉ sử dụng nhãn cấp độ ảnh.

			- Ablation study cho thấy hiệu quả của từng thành phần (đặc biệt là PRCF)
--	--	--	---

6. Ưu điểm

Công trình/ Framework	Ưu điểm
Efficient multi-kernel multi-instance learning using weakly supervised and imbalanced data for diabetic retinopathy diagnosis (2018)	- Xử lý hiệu quả giám sát yếu: Chỉ cần nhãn cấp độ ảnh. - Giải quyết tốt vấn đề mất cân bằng dữ liệu: Thông qua cơ chế lấy mẫu lại hai cấp độ BUS và BOS. - Linh hoạt với MKL: Tự động học cách kết hợp các nguồn thông tin từ nhiều kernel khác nhau. - Dựa trên thực thể có ý nghĩa lâm sàng: Các HMA candidates là dấu hiệu sớm của DR. - Hiệu suất cạnh tranh: Đạt kết quả tốt trên Messidor.
Collaborative learning of weakly-supervised domain adaptation for diabetic retinopathy grading on retinal images (2022)	- Giải quyết vấn đề Domain Shift: Framework được thiết kế để thích ứng với sự khác biệt giữa các tập dữ liệu. - Học phối hợp End-to-End: Tối ưu hóa đồng thời các thành phần, giúp chúng tương tác và cải thiện lẫn nhau. - Khả năng diễn giải cao: Bản đồ chú ý từ MIL-Attention làm nổi bật các vùng tổn thương, hỗ trợ bác sĩ. - Tận dụng giám sát yếu hiệu quả: Chỉ cần nhãn tổn thương ở miền nguồn và nhãn ảnh ở miền đích. - Kết quả SOTA: Đạt hiệu suất cao trên các tập dữ liệu chuẩn.
Weakly Supervised Lesion Detection Guides Diabetic Retinopathy Grading (2024)	- Tiếp cận mới lạ với "Prompt-based Learning": Sử dụng thông tin tổn thương giám sát yếu như một "gợi ý" trực quan. - Kiến trúc lai CNN-Transformer mạnh mẽ: Kết hợp ưu điểm của cả CNN (trích xuất đặc trưng cục bộ, tạo prompt) và

	Transformer (mô hình hóa toàn cục, tích hợp thông tin). - Bộ mã hóa PRCF hiệu quả: Kết hợp tốt thông tin tổn thương cục bộ và thông tin ảnh toàn cục, giảm khoảng cách ngữ nghĩa. - Hiệu suất SOTA chỉ với nhãn cấp độ ảnh: Vượt trội nhiều phương pháp hiện có mà không cần chú thích tổn thương chi tiết. - Tính linh hoạt và khả năng mở rộng: Các backbone có thể thay thế. - Cải thiện khả năng diễn giải: Thông qua "Lesion Prompt" và bản đồ chú ý.
--	--

7. Hạn chế / Hướng phát triển

Công trình/Framework	Hạn chế / Hướng phát triển
Efficient multi-kernel multi-instance learning using weakly supervised and imbalanced data for diabetic retinopathy diagnosis (2018)	- Phụ thuộc vào chất lượng phát hiện HMA ban đầu: Nếu thuật toán phát hiện bỏ sót tổn thương thật hoặc tạo quá nhiều dương tính giả, hiệu suất sẽ bị ảnh hưởng. - Độ phức tạp của MKL: Việc chọn và tối ưu hóa nhiều kernel có thể phức tạp và tốn kém tính toán. - Tính tổng quát của BUS: Bộ lọc thực thể huấn luyện trên một tập nguồn có thể không hoàn toàn phù hợp với mọi tập đích. - Hướng phát triển: Cải thiện thuật toán phát hiện HMA, khám phá các phương pháp MKL hiệu quả hơn, phát triển kỹ thuật BUS thích ứng hơn.
Collaborative learning of weakly-supervised domain adaptation for diabetic retinopathy grading on retinal images (2022)	- Độ phức tạp của framework: Huấn luyện đồng thời nhiều thành phần (CycleGAN, Discriminator, MIL-Attention) có thể phức tạp và đòi hỏi tài nguyên tính toán lớn. - Chất lượng ảnh dịch từ CycleGAN: Chất lượng ảnh được dịch có thể ảnh hưởng đến hiệu suất của bộ phân biệt và MIL. - Độ nhạy với siêu tham số: Việc cân bằng các thành phần mất mát trong hàm mục tiêu tổng thể có thể cần tinh chỉnh kỹ lưỡng. - Hướng phát triển: Đơn giản hóa kiến trúc, cải thiện chất lượng CycleGAN, khám

	phá các cơ chế thích ứng tên miền khác, mở rộng cho nhiều miền hơn.
Weakly Supervised Lesion Detection Guides Diabetic Retinopathy Grading (2024)	- Chất lượng của "Lesion Prompt": Hiệu suất phụ thuộc vào khả năng của EfficientNet + Grad-CAM trong việc tạo ra prompt tổn thương chính xác từ giám sát yếu. - Độ phức tạp tính toán của Swin Transformer: Mặc dù hiệu quả, Swin Transformer vẫn có thể đòi hỏi tài nguyên tính toán đáng kể. - Tính mới của "Prompt" trong thị giác: Cần thêm nhiều nghiên cứu để hiểu sâu hơn và tối ưu hóa việc sử dụng prompt trực quan. - Hướng phát triển: Khám phá các phương pháp tạo prompt tốt hơn, tối ưu hóa kiến trúc PRCF, thử nghiệm với các backbone CNN và Transformer khác, áp dụng cho các bệnh lý mắt khác hoặc các bài toán ảnh y khoa khác.

Chương 3. Giải pháp.

Dựa vào những so sánh và phân tích về các tiêu chí ở Chương 2. Chúng em đã đưa ra quyết định lựa chọn Framework WSL-DR của bài báo “**Weakly Supervised Lesion Detection Guides Diabetic Retinopathy Grading**” để làm giải pháp cho chủ đề.

Câu hỏi: Tại sao lại là Framework WSL-DR mà không phải là Framework WAD-Net (SoTA)?

Trả lời:

- Đầu tiên, WSL-DR chỉ sử dụng dữ liệu có nhãn ở cấp độ ảnh (điều này rất quan trọng, bởi vì việc triển khai mô hình này vào thực tế đòi hỏi nhiều yếu tố, một trong những yếu tố về chi phí đánh nhãn cũng rất quan trọng với những nước đang phát triển và chưa phát triển). Trong khi đó WAD-Net đòi hỏi bộ dữ liệu nhãn cấp độ ảnh và nhãn ở cấp độ pixel, điều đó sẽ gây ra gánh nặng chi phí không đáng có.
- Thứ hai, việc xây dựng kiến trúc và huấn luyện mô hình WSL-DR so với WAD-Net đơn giản hơn, có thể dễ dàng triển khai với tài nguyên ít hơn.
- Thứ ba, việc một mô hình dễ triển khai, sử dụng nhãn hiệu quả hơn, lại có hiệu suất gần đạt với WAD-Net (SoTA), rất đáng để triển khai và thử nghiệm.

- Thứ tư, xu hướng mới trong học máy. Ngoài việc dễ triển khai và áp dụng vào thực tế hơn, thì việc các kỹ thuật mới được áp dụng vào trong mô hình WSL-DR. Như việc sử dụng cơ chế chú ý (attention mechanism) vào trong mô hình. Những kỹ thuật học máy mới này mở ra một tầm nhìn mới, một xu hướng trong lĩnh vực thị giác máy tính. Chúng em có thể học hỏi nhiều hơn về xu hướng thế giới đang làm gì.

Framework chúng em được xây dựng dựa vào nguyên lý và phương pháp của bài báo “**Weakly Supervised Lesion Detection Guides Diabetic Retinopathy Grading**”. Vậy nên framework WSL-DR của bài báo sẽ được mô phỏng lại và được đặt tên là **WLS-DR** của chủ đề để tránh nhầm lẫn.

Framework được thiết kế để giải quyết bài toán phân loại mức độ võng mạc tiểu đường (DR) chỉ sử dụng nhãn ở cấp độ hình ảnh. Cốt lõi của phương pháp này là ý tưởng sử dụng thông tin tổn thương được phát hiện một cách “yếu” (weakly supervised) như một “prompt” (gợi ý) để hướng dẫn mô hình Transformer phân loại DR hiệu quả hơn.

Giai đoạn Huấn luyện bao gồm 2 bước:

3.1. Bước 1: Tiền huấn luyện Mạng CNN Chú ý (Attention Convolutional Neural Networks pre-training)

1. Mục đích:

Huấn luyện một mạng CNN (cụ thể là EfficientNet) để nắm bắt các vùng hình ảnh có khả năng chứa tổn thương liên quan đến DR, chỉ dựa trên nhãn cấp độ ảnh.

2. Hoạt động:

- EfficientNet được huấn luyện trên tập dữ liệu ảnh đáy mắt với nhiệm vụ phân loại đa lớp mức độ nghiêm trọng của DR. Mỗi mức độ DR (ví dụ: 0-Không DR, 1-Nhẹ, 2-Trung bình, 3-Nặng, 4-Tăng sinh) được coi là một lớp riêng biệt.
- **Hàm mất mát (Loss Function):** Sử dụng **Mean Squared Error (MSE)**:

$$L_{cl} = \frac{1}{N} \sum_{i=0}^N (x_i - y_i)^2 \quad (1)$$

Trong đó $\{x_1, \dots, x_N\}$, $\{y_1, \dots, y_N\}$ là các nhãn dự đoán và nhãn đầu ra của mô hình (ground-truth).

Câu hỏi: Kỹ thuật weakly supervised được dùng ở đâu?

Trả lời: Kỹ thuật weakly supervised được dùng ở ngay trong bước này. Chúng ta không có thông tin vị trí tổn thương chính xác. Thay vào đó, mạng CNN

(EfficientNet) học cách liên kết các đặc trưng hình ảnh với nhãn DR ở cấp độ toàn bộ ảnh. Sau khi huấn luyện, các kỹ thuật như Grad-CAM sẽ được sử dụng để xem mạng nó đã nhìn vào chỗ nào để đưa ra quyết định phân loại. Vùng mà mạng tập trung vào được coi là vùng tổn thương tiềm năng, nó được phát hiện một cách “yếu”.

3. Kết quả của bước này:

Một mạng EfficientNet đã được huấn luyện, có khả năng (dù không hoàn hảo) xác định các vùng liên quan đến DR. Quan trọng là, trong bước tiếp theo, **EfficientNet** này chỉ được sử dụng để tạo heatmap và không được huấn luyện lại (no gradient backpropagation).

3.2. Bước 2: Huấn luyện Framework PLST (Prompt-based Lesion-fuse Swin Transformer)

Đây là trái tim của phương pháp, bao gồm các mô-đun con trong framework

1. Mô-đun Chú ý (Attention Module): Tạo “Lesion Prompt”

- **Mục đích:** Trích xuất "gợi ý tổn thương" (Lesion Prompt) từ ảnh đầu vào, làm nổi bật các vùng nghi ngờ có tổn thương.
- **Đầu vào:** Ảnh đáy mắt gốc P .
- **Hoạt động:**
 1. Ảnh P được đưa qua mạng EfficientNet đã tiền huấn luyện (từ Bước 1).
 2. Sử dụng Grad-CAM để tạo ra “heatmap” Y_G từ lớp tích chập cuối cùng của EfficientNet (công thức (2), (3)). Heatmap này làm nổi bật các vùng mà EfficientNet đã “chú ý” đến khi phân loại DR. Các vùng có giá trị cao trong heatmap được cho là có khả năng chưa tổn thương.

$$w_k = \frac{1}{Z} \sum_{i=1}^W \sum_{j=1}^H \frac{\partial y}{\partial X_{ij}^k} \quad (2)$$

Trong đó, w_k là trọng số của kênh thứ k , Z là hằng số chuẩn hóa (số lượng feature map, $W \times H$), y là điểm số của lớp c (hoặc là điểm số đầu ra của nơ-ron cuối cùng), X_{ij}^k là giá trị kích hoạt tại vị trí (i, j) của kênh (feature map) thứ k trong lớp tích chập được chọn

Công thức (2) tính toán “tầm quan trọng” của mỗi kênh (feature map) k trong lớp tích chập cuối cùng (X^k) đối với việc dự đoán score y . Các kênh quan trọng hơn sẽ có trọng số w_k lớn hơn.

$$Y_G = \text{ReLU} \left(\sum_{k=1}^K w_k \cdot X^k \right) \quad (3)$$

Trong đó, Y_G là heatmap kết quả của Grad-CAM đầu ra, $\text{ReLU}(\cdot)$ là hàm kích hoạt Rectified Linear Unit, $\text{ReLU}(x) = \max(0, x)$. Nó đảm bảo rằng chúng ta chỉ quan tâm đến các đặc trưng có ảnh hưởng tích cực đến việc dự đoán lớp quan tâm.

Công thức (3) tạo ra heatmap Grad-CAM Y_G . Heatmap là một tổ hợp tuyến tính có trọng số của các feature map X^k , sau đó được đưa qua hàm ReLU. Các vùng trong heatmap có giá trị dương cao cho biết những vị trí trong ảnh mà mô hình chú ý đến nhiều nhất để đưa ra dự đoán.

Câu hỏi: Grad-CAM chỉ đúng được 50% thôi, vậy người ta đã xử lý như thế nào để làm tăng thông tin để phân loại DR? (Câu hỏi này sẽ đi xuyên suốt qua các công đoạn trong framework, em sẽ làm rõ và trả lời từng phần một.) (1) – Nhận diện vấn đề.

Trả lời: Heatmap từ Grad-CAM (hoặc các phương pháp CAM nói chung) có thể không hoàn toàn chính xác và có thể chứa nhiều và bỏ sót thông tin. Heatmap này chỉ là một “ước lượng yếu” về vị trí tổn thương.

3. Chuẩn hóa heatmap Y_G để thu được “bản đồ trọng số chú ý” V . Quá trình chuẩn hóa này giúp đưa các giá trị về một khoảng nhất định, làm giảm sự biến thiên và có thể giúp ổn định quá trình học.

$$v_i = \frac{y_i - \min_{1 \leq i \leq n} \{y_i\}}{\max_{1 \leq i \leq n} \{y_i\}} \quad (4)$$

Trong đó, V_i là giá trị chuẩn hóa tại vị trí i của bản đồ trọng số chú ý V , Y_i là giá trị của heatmap Y_G tại vị trí i .

Công thức (4) thực hiện chuẩn hóa min-max trên heatmap Y_G để tạo ra bản đồ trọng số chú ý V . Các giá trị trong V sẽ nằm trong khoảng $[0, 1]$. Điều này giúp đưa các giá trị chú ý về một thang đo chung và có thể giúp ổn định quá trình học.

4. Tạo Lesion Prompt G : Thực hiện phép nhân Hadamard giữa bản đồ trọng số V và ảnh gốc P .

$$g_i = P_i \otimes v_i \quad (5)$$

Phép nhân này có tác dụng “lọc” ảnh gốc. Những vùng có trọng số chú ý cao trong V (nghĩa là vùng nghi ngờ có tổn thương) sẽ được giữ lại các giá trị pixel gốc, trong khi những vùng có trọng số chú ý thấp (vùng nền, không liên quan) sẽ có giá trị pixel bị giảm đi đáng kể (tiệm cận 0). Kết quả là một “Lesion Prompt” G – một phiên bản của ảnh chỉ tập trung vào các vùng tổn thương tiềm năng

Câu hỏi: Grad-CAM chỉ đúng được 50% thôi, vậy người ta đã xử lý như thế nào để làm tăng thông tin để phân loại DR? (2) – Bước xử lý ban đầu.

Trả lời: Việc tạo ra Lesion Prompt G là bước đầu tiên để cố gắng tinh lọc thông tin từ Grad-CAM. Thay vì dùng trực tiếp heatmap thô, dùng nó để “mặt nạ hóa” ảnh gốc, giữ lại thông tin pixel chi tiết ở những vùng được Grad-CAM cho là quan trọng.

2. Bộ mã hóa Trường Tiếp nhận Kênh dựa trên Prompt (PRCF Encoder - Prompt-based Receptive Channel Field Encoder): Hợp nhất thông tin

- **Mục đích:** Kết hợp một cách thông minh và hiệu quả thông tin từ “Lesion Prompt” G (thông tin tổn thương cục bộ, chi tiết nhưng có thể nhiễu) với thông tin từ ảnh gốc P (thông tin toàn cục, ngữ cảnh nhưng có thể bị các vùng không liên quan làm loãng).
- **Đầu vào:** Lesion Prompt G và ảnh gốc P (hoặc đặc trưng toàn cục từ ảnh gốc).
- **Hoạt động:**

1. Nối (Concatenate):

G và P được nối lại với nhau theo chiều kênh để tạo thành một khối đặc trưng kết hợp F .

$$F = \text{concat}[p_1, \dots, p_n, g_1, \dots, g_n] \quad (6)$$

Công thức (6) kết hợp thông tin từ ảnh gốc P (chứa thông tin toàn cục và ngữ cảnh) và Lesion Prompt G (chứa thông tin tổn thương cục bộ đã được làm nổi bật) bằng cách nối chúng lại với nhau theo chiều kênh.

Điều này tạo ra một khối đặc trưng F phong phú hơn.

2. Mô-đun Hợp nhất Kênh (Channel Fusion Module):

- Lấy cảm hứng từ SENet, mô-đun này học cách tự động gán trọng số cho từng kênh trong khối đặc trưng F .
- Sử dụng Global Average Pooling trên F để thu được vector thống kê kênh z_c .

$$z_c = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W f_c(i, j) \quad (7)$$

- z_c được đưa qua hai lớp Fully-Connected (FC) với hàm kích hoạt ReLU (δ) và Sigmoid (σ) để tạo ra các trọng số kênh s .

$$\mathbf{s} = \sigma(W_2 \delta(W_1 \mathbf{z})) \quad (8)$$

Trong đó, $\mathbf{s}$ là vector chứa các trọng số kênh s_c , W_1 W_2 là ma trận trọng số của lớp FC thứ nhất và thứ hai.

Đây là bước “kích thích” trong SENet. Vector thống kê kênh z được đưa qua 2 lớp Fully-Connected (W_1 , W_2) với các hàm kích hoạt ReLU (δ) và Sigmoid (σ) để học ra các trọng số s cho mỗi kênh. Các trọng số này cho biết mức độ quan trọng tương đối của kênh.

- Các trọng số s này được nhân với các kênh tương ứng của F .

$$\tilde{f}_c = F_{rescale}(f_c, s_c) = s_c f_c \quad (9)$$

Trong đó $\tilde{f}_c$ là kênh thứ c của khối đặc trưng đã được điều chỉnh, $F_{rescale}(\cdot, \cdot)$ là phép toán điều chỉnh lại thang đo, f_c là kênh thứ c của khối đặc trưng F ban đầu, s_c là trọng số của kênh thứ c .

Các kênh f_c của khối đặc trưng F ban đầu được nhân với các trọng số kênh s_c tương ứng. Điều này giúp nhấn mạnh các kênh quan trọng và làm suy yếu các kênh ít quan trọng hơn, tạo ra khối đặc trưng mới $\tilde{F}$ (gồm các $\tilde{f}_c$).

Câu hỏi: Grad-CAM chỉ đúng được 50% thôi, vậy người ta đã xử lý như thế nào để làm tăng thông tin để phân loại DR? (3) – Tăng cường và chọn lọc thông tin

Trả lời: Channel Fusion Module đóng vai trò quan trọng ở đây. Bằng cách học trọng số cho từng kênh, mô hình có thể **chọn lọc và nhấn mạnh các kênh đặc trưng thực sự hữu ích** từ cả Lesion Prompt (có thể chứa thông tin tổn thương tốt nhưng cũng có thể chứa nhiễu từ Grad-CAM) và ảnh gốc. Nó giúp **giảm thiểu ảnh hưởng của các kênh nhiễu hoặc không liên quan** mà Grad-CAM có thể đã tạo ra trong Lesion Prompt.

3. Mô-đun Tiếp nhận (Receptive Module):

- Lấy cảm hứng từ Receptive Field Block (RFB), mô-đun này được thiết kế để tăng cường khả năng phân biệt của các đặc trưng và mở rộng trường tiếp nhận.
- Đặc trưng $\tilde{F}$ (đầu ra từ Channel Fusion Module) được đưa qua nhiều nhánh tích chập với các kích thước kernel khác nhau (multi-scale convolutions). Điều này giúp mô hình nắm bắt thông tin ở các tỷ lệ khác nhau.
- Kết quả từ các nhánh này được hợp nhất.

- Kết nối dư (Residual Connection): Đặc trưng hợp nhất này được cộng với thông tin ảnh toàn cục gốc P .

Câu hỏi: Grad-CAM chỉ đúng được 50% thôi, vậy người ta đã xử lý như thế nào để làm tăng thông tin để phân loại DR? (4) – Bổ sung ngữ cảnh và làm giàu đặc trưng

Trả lời: Receptive Module giúp làm giàu thêm các đặc trưng đã được chọn lọc. Việc sử dụng multi-scale convolutions giúp nắm bắt các tổn thương ở nhiều kích thước.

Quan trọng hơn, **kết nối dư với ảnh gốc P đảm bảo rằng thông tin toàn cục, ngữ cảnh từ ảnh gốc không bị mất đi hoàn toàn.** Ngay cả khi Lesion Prompt từ Grad-CAM không hoàn hảo, việc kết hợp trở lại với ảnh gốc P (đặc biệt là thông qua kết nối dư, giúp tín hiệu gốc dễ dàng truyền qua) cung cấp một "lưới an toàn" thông tin. Nếu prompt sai, mô hình vẫn có thể dựa vào thông tin từ P .

3. Mô-đun Phân loại (Classification Module): Đưa ra quyết định cuối cùng

- **Mục đích:** Phân loại mức độ DR dựa trên các đặc trưng đã được làm giàu và hợp nhất.
- **Đầu vào:** Đặc trưng đầu ra từ PRCF Encoder.
- **Hoạt động:**
 - Các đặc trưng này được đưa vào một mạng **Swin Transformer**
 - Swin Transformer, với cơ chế self-attention dựa trên cửa sổ dịch chuyển (shifted window self-attention), có khả năng mô hình hóa hiệu quả các mối quan hệ xa và gần trong các đặc trưng đầu vào. Nó có thể tích hợp thông tin từ cả Lesion Prompt (đã được tinh lọc qua PRCF) và thông tin toàn cục một cách hiệu quả để đưa ra dự đoán cuối cùng.
 - **Hàm mất mát phân loại (Cls Loss):** Thường là Cross-Entropy cho bài toán phân loại đa lớp.

Câu hỏi: Grad-CAM chỉ đúng được 50% thôi, vậy người ta đã xử lý như thế nào để làm tăng thông tin để phân loại DR? (5) – Tận dụng mô hình mạnh để tích hợp thông tin.

Trả lời: Swin Transformer đóng vai trò cuối cùng trong việc xử lý thông tin. Ngay cả khi thông tin từ Grad-CAM (đã qua xử lý bởi Attention Module và PRCF Encoder) vẫn còn một chút không chắc chắn, khả năng mô hình hóa mạnh mẽ của Transformer giúp nó "cân nhắc" và tích hợp tất cả các nguồn thông tin (cả phần prompt tổn thương và phần ngữ cảnh toàn cục) để đưa ra quyết định phân loại cuối cùng một cách tốt

nhất có thể. Transformer có thể học được các mối quan hệ phức tạp giữa các vùng tổn thương tiềm năng và ngữ cảnh xung quanh.

4. (Tùy chọn) Mô-đun Thay thế (Alternative Module):

- Áp dụng cho các bộ dữ liệu cung cấp ảnh của cả hai mắt (ví dụ: EyePACS).
- Nối đặc trưng từ cả hai mắt (sau khi mỗi mắt đã qua các mô-đun trên) và huấn luyện một mạng nhỏ (ví dụ: 3 lớp FC) để đưa ra dự đoán cuối cùng, tận dụng thông tin bổ sung.

Chương 4. Cài đặt và thử nghiệm mô hình.

Do thiết bị của chúng em hạn chế cho nên mục tiêu của cài đặt và thử nghiệm là việc chạy được mô hình theo lý thuyết được đề ra trước đó. Cho nên kết quả của mô hình không mang nhiều ý nghĩa điển giải.

Đồng thời chúng em cũng cố gắng để làm cho mô hình có khả năng học tốt hơn, bằng cách thử huấn luyện với GPU tốt hơn. Trước hết mô hình sẽ chia ra 2 cấu hình để huấn luyện.

- Cấu hình 1: Size ảnh 224x224. Batch size 16. Learning rate 1e-5, GPU GTX 3060 6GB
- Cấu hình 2: Size ảnh 512x512, Batch size 40. Learning rate 1e-5, GPU T4 x 2 16GB
- Tập dữ liệu huấn luyện EYEPAACS
 - o Train dataset size: 28098
 - o Validation dataset size: 7025

Mô hình được chia thành 2 lần huấn luyện. Bao gồm tiền huấn luyện mô hình CNN EfficientNet và huấn luyện PLST (Prompt-based Lesion-fuse Swin Transformer) với backbone là Swin Transformer.

Nhấn mạnh: Việc huấn luyện mô hình CNN này rất quan trọng. Nếu việc mô hình CNN học không tốt, hay kết quả không mang ý nghĩa, thì các bước sau sẽ sai hết.

4.1. Tiền huấn luyện mô hình CNN EfficientNet để tạo heatmap.

4.1.1. Đối với cấu hình 1:

- Dữ liệu đầu vào:
 - Kích thước ảnh: 224x224 (Kích thước gốc được sử dụng là 896x896)
 - Batch size: 16 (Batch size gốc là 40)

Mô hình CNN được sử dụng để huấn luyện là 'efficientnet_b0' với epoch = 50, và Validation Loss = 0.3896.

Kết quả thử nghiệm khi lấy 1 ảnh để kiểm thử heatmap dựa vào GradCAM.




Figure 2: Kết quả khi áp dụng GradCAM vào 1 ảnh ngẫu nhiên

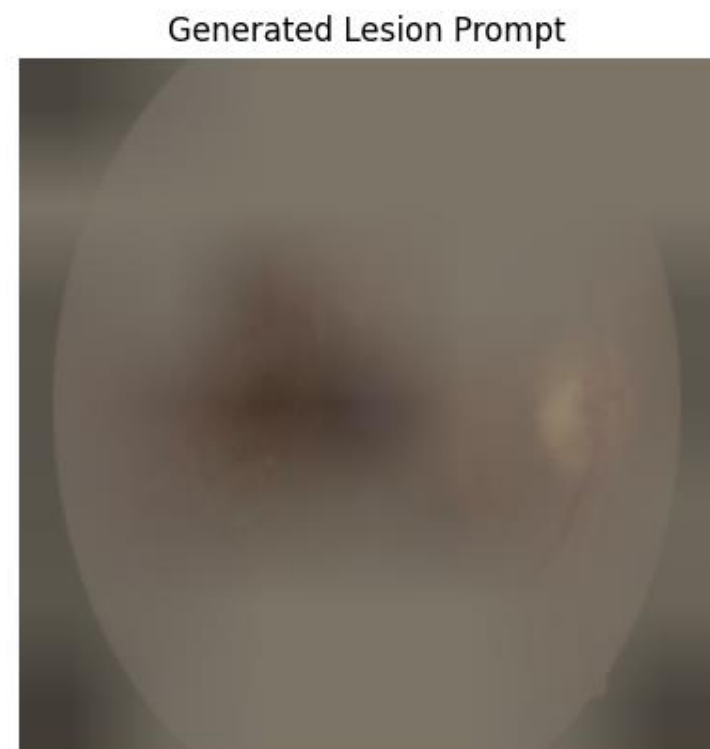


Figure 3: Kết quả tập trung vào vùng bệnh

Em đánh giá kết quả khi huấn luyện với cấu hình một này chưa được tốt lắm. Ảnh bị mờ rất nhiều, nhưng nếu nhìn kỹ vào vùng mà ảnh tập trung thì cũng nhìn ra được những lốm đốm nhỏ, điều đó cho thấy mô hình đã học được đúng chỗ. Tuy nhiên heatmap phân bố bị sai sót, nó phân bố hầu như toàn ảnh, heatmap chỉ tập trung vào trong ảnh mắt, vẫn rất vớ vẩn. Vì thế nên em chưa hài lòng nên đã tìm cách để huấn luyện thêm cho ra kết quả tốt hơn

4.1.2. Đối với cấu hình 2

- Dữ liệu đầu vào:

- Kích thước ảnh: 512x512 (Kích thước gốc được sử dụng là 896x896)
- Batch size: 40

Mô hình cnn được sử dụng để huấn luyện là 'efficientNet_b0' với epoch = 100 và validation loss = 0.3075. Rất đáng kể so với cấu hình 1

Kết quả khi heatmap bằng GradCAM




Figure 4: Kết quả khi heatmap với cấu hình tốt hơn

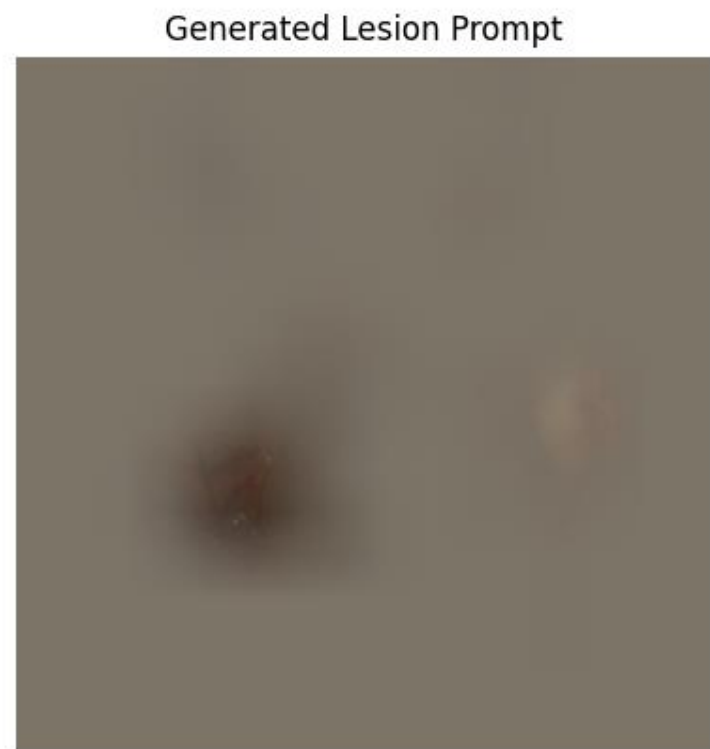


Figure 5: Kết quả đã tập trung vào vùng bệnh

Sau khi được tăng cấu hình huấn luyện lên, độ sai lệch giảm xuống rất tốt, đồng thời dữ liệu tập trung vào vùng bệnh cũng rõ ràng hơn. Từ đó tập trung vào các bước sau sẽ tốt hơn rất nhiều.

4.2. Huấn luyện mô hình hoàn chỉnh WLS-DR

Trong phần này, vì độ phức tạp cũng như cần tài nguyên tính toán lớn, đồng thời do thời gian có hạn nên chúng em chỉ có thể huấn luyện được mô hình theo cấu hình 1. Và cho ra kết quả chưa được tốt lắm.

4.2.1 Cấu hình 1

Lần này mô hình được đánh giá bằng độ đo $\kappa = 0.6942$

Kích thước ảnh 224x224, batch size 16,

Kết quả khi test trên 2 ảnh ngẫu nhiên




Figure 6: Kết quả phân loại DR và heatmap bổ sung

Nhận xét về kết quả trên, rất tệ, các vùng tập trung chưa chính xác, heatmap tập trung chỗ khác nhau, kết quả không mang nhiều ý nghĩa

4.2.2. Cấu hình 2.

Như đã trình bày ở trên, do độ phức tạp của cấu trúc và khả năng tính toán lớn vì cấu hình cao, cho nên em chưa thể hoàn thành việc huấn luyện. Em sẽ trình bày trong phần hạn chế.

Chương 5. Hạn chế và hướng phát triển

Hạn chế ở đây em xin trình bày 2 ý chính: hạn chế của tụi em khi xây dựng mô hình và hạn chế của mô hình gốc được tác giả nêu rõ trong bài báo gốc.

5.1 Hạn chế

1. Hạn chế của chúng em khi xây dựng mô hình.

Hạn chế lớn nhất khi tụi em khi xây dựng một mô hình phân loại lớn như thế này là tài nguyên tính toán để huấn luyện các mô hình từ con số 0.

Như chúng em đã trình bày ở trong chương 4 về việc huấn luyện với cấu hình số 2. Thời gian huấn luyện một mô hình CNN, epoch 100 với cấu hình 1 mất hơn 35

giờ, không chỉ phải thử nghiệm liên tục để tối ưu khả năng học của mô hình, đồng thời việc gặp lỗi thường xuyên mà phải sửa lỗi thường xuyên rất khó khăn với một cấu hình bé để thử nghiệm lặp đi lặp lại. Cho nên việc kết quả không tốt là điều tất yếu.

Hạn chế của mô hình của tụi em nữa là việc xây dựng mô hình từ con số 0, cho nên cách trình bày cấu trúc thư mục cũng như các đoạn code còn lộn xộn rất nhiều.

2. Hạn chế của mô hình

Bộ mã hóa PRCF được đề xuất có thể tự động bỏ qua hoặc làm suy yếu một số thông tin cơ bản, điều này có thể ảnh hưởng đến việc đánh giá kết quả phân loại DR.

5.2 Hướng phát triển

Hướng phát triển này nói về hướng phát triển của mô hình tụi em xây dựng.

- Tụi em sẽ vẫn tập trung vào việc làm sao để các mô hình học tốt hơn và tiêu tốn ít chi phí hơn, qua việc đào tạo ở cấu hình 2 cho thấy, kết quả đạt được đã là rất tốt. Tuy nhiên thì so với kết quả mà bài báo công bố thì còn rất xa vời.
- Tụi em sẽ đào sâu vào cấu trúc của các mô hình học sâu để tối ưu hơn nữa. Vì ý nghĩa của mô hình này là chữa bệnh mang đến trách nhiệm quan trọng và lớn lao, phải hạn chế xảy ra sai sót.
- GradCAM vẫn còn chưa đủ chắc chắn, do đó rất đáng để quan tâm các thuật toán để có thể thay thế GradCAM và mang lại hiệu quả tốt hơn.

Chương 6. Tham khảo

[1] [Poster A0 Bo Y te benh vong mac tieu duong 2022.](#)

[2] [Peng Cao, Fulong Ren, Chao Wan, Jinzhu Yang and Osmar Zaiane “Efficient multi-kernel multi-instance learning using weakly supervised and imbalanced data for diabetic retinopathy diagnosis” in 2018 Computerized Medical Imaging and Grap](#)

[3] [Peng Cao, Qingshan Hou, Ruoxian Song, Haonan Wang, Osmar Zaiane “Collaborative learning of weakly-supervised domain adaptation for diabetic retinopathy grading on retinal images” in 2022 Computers in Biology and Medicine](#)

[4] [Anonymous Authors “Weakly Supervised Lesion Detection Guides Diabetic Retinopathy Grading” in 2024](#)